




Jhon Quiza

Árboles de decisión

Vamos a jugar un poco... adivina el personaje






Y el personaje es...


¿Qué es un árbol de decisión?

- Es una estructura que nos permite dividir el conjunto de datos en ramas y tomar decisiones simples en cada nivel. Esto nos permitirá llegar a una decisión final caminando hacia abajo del árbol.



Elementos de un árbol de decisión

- Nodo raíz: característica principal del modelo.
- Nodos interiores: las otras características.
- Arcos: posibles valores que puede tomar cada característica.
- Hojas: decisiones / predicciones.



¿Cómo se construyen?

Day	Outlook	Temp	Humidity	Wind	Tennis
1	 Sunny	Hot	 High	 Weak	No
2	 Sunny	Hot	 High	 Strong	No
3	 Overcast	Hot	 High	 Weak	Yes
4	 Rain	Mild	 High	 Weak	Yes
5	 Rain	Cool	 Normal	 Weak	Yes
6	 Rain	Cool	 Normal	 Strong	No
7	 Overcast	Cool	 Normal	 Weak	Yes

¿Cómo se construyen?

Day	Outlook	Temp	Humidity	Wind	Tennis
1	 Sunny	Hot	 High	 Weak	No
2	 Sunny	Hot	 High	 Strong	No
3	 Overcast	Hot	 High	 Weak	Yes
4	 Rain	Mild	 High	 Weak	Yes
5	 Rain	Cool	 Normal	 Weak	Yes
6	 Rain	Cool	 Normal	 Strong	No
7	 Overcast	Cool	 Normal	 Weak	Yes

¿Por qué
atributo
empiezo?



¿Cómo elegir el mejor atributo en cada nodo?

- Existen varios criterios para elegir el mejor atributo:
- En clasificadores, los criterios más usados son la entropía y el índice de impurezas de Gini.
- En regresores, el MSE, MAE y desviación de Poisson.

La entropía

- La entropía es un concepto que procede de la teoría de la información y que mide la impureza de los valores de la muestra. Se define por:

$$H(S) = - \sum_{c \in C} p(c) \log_2 p(c)$$

- S representa el conjunto de datos en el que se calcula la entropía
- c representa las clases en conjunto, S
- p(c) representa la proporción de puntos de datos que pertenecen a la clase c respecto del número total de puntos de datos del conjunto, S.

La entropía

- Los valores de entropía pueden estar comprendidos entre 0 y 1.
- Si todas las muestras del conjunto de datos, S , pertenecen a una clase, entonces la entropía será igual a cero. Si la mitad de las muestras se clasifican en una clase y la otra mitad en otra, la entropía alcanzará su máximo en 1.
- Con el fin de seleccionar la mejor característica para dividir y encontrar el árbol de decisión óptimo, se debe utilizar el atributo con la menor cantidad de entropía.

Ganancia de información de un atributo

Representa la diferencia en la entropía antes y después de una división en un atributo dado.

$$GI(S, a) = H(S) - \sum_{v \in \text{values}(a)} \frac{|S_v|}{|S|} H(S_v)$$

Donde:

- a representa un atributo específico
- La entropía (S) es la entropía del conjunto de datos, S .
- $|S_v|/|S|$ representa la proporción de los valores en S_v al número de valores en el conjunto de datos, S .

El atributo con la mayor ganancia de información producirá la mejor división, ya que está haciendo el mejor trabajo al clasificar los datos de entrenamiento de acuerdo con su clasificación de destino.

Calculemos la ganancia de información

Day	Outlook	Temp	Humidity	Wind	Tennis
1	 Sunny	Hot	 High	 Weak	No
2	 Sunny	Hot	 High	 Strong	No
3	 Overcast	Hot	 High	 Weak	Yes
4	 Rain	Mild	 High	 Weak	Yes
5	 Rain	Cool	 Normal	 Weak	Yes
6	 Rain	Cool	 Normal	 Strong	No
7	 Overcast	Cool	 Normal	 Weak	Yes

Índice de impureza de Gini

- La impureza de Gini es la probabilidad de clasificar incorrectamente un punto de datos aleatorio del conjunto de datos si se etiquetara en función de la distribución de clases del conjunto de datos. Se calcula como:

$$Gini(s) = 1 - \sum_i (p_i)^2$$

- Donde:
 - S es el conjunto de datos.
 - p_i es la proporción de muestras que pertenecen a la clase i en el conjunto de datos S.
 - Σ representa la suma de todas las clases.

Ejemplo de cálculo del índice de Gini

Imaginemos un nodo con 4 elementos, y sus clases están distribuidas de la siguiente manera: 3 elementos de la clase A y 1 elemento de la clase B.

La proporción de cada clase sería:

$$p_A = 3/4 = 0.75$$

$$p_B = 1/4 = 0.25$$

Entonces, la impureza de Gini sería:

$$Gini = 1 - (0.75^2 + 0.25^2) = 0.375$$

Esto indica que hay un 37.5% de "probabilidad" de que un elemento sea clasificado incorrectamente si se asigna al azar en ese nodo.

¿Cómo se utiliza en árboles de decisión?

En los árboles de decisión:

- 1. División de nodos:** Durante el proceso de construcción del árbol, en cada nodo, se evalúan todas las posibles divisiones (por cada variable y cada valor de corte) y se calcula la impureza de Gini para cada división.
- 2. Selección de la mejor división:** Se selecciona la división que minimice la impureza de Gini. Esto significa que el árbol busca la división que produzca dos nodos hijos más "puros", es decir, con una mayor concentración de un solo tipo de clase en cada uno de los nodos.

Cálculo en nodos hijo

Supongamos que se tiene un nodo con un conjunto de datos que se divide en dos nodos hijos L y R .

La impureza ponderada de Gini para este nodo se calcula como la suma de las impurezas de Gini de los nodos hijos, ponderada por el tamaño de cada uno:

$$Gini_{split} = \frac{|L|}{|L| + |R|} \cdot Gini(L) + \frac{|R|}{|L| + |R|} \cdot Gini(R)$$

Donde:

- $|L|$ y $|R|$ son el número de elementos en los nodos izquierdo y derecho, respectivamente.
- $Gini(L)$ y $Gini(R)$ son las impurezas de Gini de los nodos izquierdo y derecho, respectivamente.

La división que minimiza el valor de $Gini_{split}$ será seleccionada.

Diferencias clave con la entropía

Cálculo:

- El índice de Gini es computacionalmente más eficiente que la entropía, ya que no requiere el cálculo de logaritmos.

Sensibilidad:

- El índice de Gini tiende a favorecer divisiones que crean nodos hijos de igual tamaño, mientras que la entropía puede favorecer divisiones que crean un nodo hijo muy puro, incluso si es pequeño.

Ventajas de los árboles de decisión

- Fáciles de entender e interpretar (especialmente árboles pequeños).
- Pueden capturar relaciones no lineales entre las características y la variable objetivo.
- Proceso de aprendizaje relativamente rápido.
- Selección de características implícita (las características más importantes tienden a aparecer más cerca de la raíz).
- No requieren gestión de datos nulos.
- No requieren procesamiento de variables numéricas.

Desventajas de los árboles de decisión

- Tendencia al sobreajuste (overfitting) si no se regularizan.
- Pueden ser sensibles a pequeñas variaciones en los datos de entrenamiento.
- Para regresión, pueden producir predicciones discontinuas (constantes en las hojas).

Vamos al código...

Árboles de decisión para regresión

¿Qué sucede si el objetivo es continuo?

- El objetivo del árbol ya no es clasificar, si no estimar un valor numérico.
- En lugar de buscar la pureza de clases, el árbol intenta encontrar divisiones que minimicen el **error de predicción**. Se usan funciones de pérdida como el error cuadrático medio (MSE) o el error absoluto medio (MAE).
- Un árbol de regresión parte el espacio en regiones donde la respuesta es **relativamente constante**, y predice en cada hoja el valor promedio (o mediano) de los datos que caen allí.

Funcionamiento del árbol de regresión

- División del espacio: el árbol analiza todas las posibles divisiones de los datos (por cada variable predictora y valor de corte) y selecciona aquella que minimiza el error de las predicciones.
- Criterio de división: se utiliza una función de pérdida basada en la distancia entre el valor real y el valor predicho. La más común es MSE.
- Predicción en las hojas: Una vez dividido el espacio, cada hoja del árbol contiene un subconjunto de datos. El modelo predice el valor medio (o mediano) de esos datos.

¿Por qué funcionan mejor?

- Podemos pensar que el árbol está construyendo una función por tramos, es decir, una función que asigna un valor promedio distinto en cada "pedazo" del espacio de entrada.
- A diferencia de una regresión lineal (que asume una relación global entre variables), un árbol de regresión se adapta localmente, lo que lo hace muy flexible.
- Esa misma flexibilidad puede hacer que el modelo memorice los datos de entrenamiento si no se limita su profundidad o el número mínimo de datos en las hojas. Por eso, se deben aplicar técnicas de regularización para evitar el sobreajuste.

Vamos al código...