

Evaluación de modelos

Jhon Quiza

¿Cómo sé que mi modelo de ML es bueno?

Métrica de evaluación

- Tenemos un modelo entrenado que puede hacer predicciones:

$$\hat{y} = f_{\hat{w}}(x) = \hat{f}(x)$$

- La métrica de evaluación nos permitirá evaluar el modelo a partir de la cuantificación de las diferencias entre los valores reales y los estimados:

$$L(y, \hat{f}(x))$$

- Ejemplos de funciones de pérdida:

- Error absoluto: $L(y, \hat{f}(x)) = |y - \hat{f}(x)|$
- Error cuadrático: $L(y, \hat{f}(x)) = (y - \hat{f}(x))^2$

Métricas


- Error cuadrático medio:

$$\text{MSE}(\hat{w}) = \frac{1}{N} \sum_{i=1}^N (y_i - f_{\hat{w}}(x_i))^2$$


- Raíz del error cuadrático medio:

$$\text{RMSE}(\hat{w}) = \sqrt{\text{MSE}(\hat{w})}$$


Error de entrenamiento versus complejidad del modelo




Error de entrenamiento versus complejidad del modelo




Error de entrenamiento versus complejidad del modelo



Error de entrenamiento versus complejidad del modelo




¿Es el error de entrenamiento una buena medida de desempeño del modelo?





¿Es el error de entrenamiento una buena medida de desempeño del modelo?

El error de entrenamiento es muy optimista porque los parámetros se ajustan a los datos de entrenamiento, pero no es un indicador de la capacidad del modelo de hacer buenas predicciones.




Error de prueba



- Nos permite aproximar **el error de generalización**.
- Consiste en calcular el error con datos **que no están en el conjunto de entrenamiento**.





Error de prueba versus complejidad del modelo





Error de prueba versus complejidad del modelo





Error de prueba versus complejidad del modelo



Error de prueba versus complejidad del modelo



Error de prueba versus complejidad del modelo





Error de generalización

- Lo ideal sería poder calcular el error en todas las observaciones posibles, no sólo en las que están en el dataset. Esto sería el error de generalización.
- Formalmente el error de generalización se define como el valor esperado del error de prueba.

$$\text{Error de generalización} = E_{x,y}[L(y, f_{\hat{w}}(x))]$$


- Este error depende de la distribución de probabilidad de las entradas y las salidas.



Validación cruzada para calcular el error de generalización

¡El problema del error de generalización es que no se puede calcular!

Pero se puede aproximar evaluando el modelo con varios conjuntos de prueba.



Vamos al código...

Error, sesgo y varianza

$$E \left(y_0 - \hat{f}(x_0) \right)^2 = Var \left(\hat{f}(x_0) \right) + [Bias \hat{f}(x_0)]^2 + Var(\epsilon)$$


$$MSE = Varianza + Sesgo^2 + Ruido$$

Sesgo: Error debido a la diferencia entre el modelo y el mundo real.

Varianza: medida de que tanto cambia el modelo si se estrena con conjuntos de datos diferentes.

Sesgo



¿En promedio, qué tan bien se ajusta mi modelo con conjuntos de datos diferentes?



$$\text{bias}(f_{\hat{w}}(x_t)) = f_w(x_t) - f_{\bar{w}}(x_t)$$


Sesgo

Modelos complejos tienen menor sesgo.



Varianza



¿Qué tan diferentes son los modelos que obtengo al cambias los datos?




$$\text{var}(f_{\hat{w}}(x_t)) = E_{\text{train}} \left[\left(f_{\hat{w}(\text{train})}(x_t) - f_{\bar{w}}(x_t) \right)^2 \right]$$

Varianza


Modelos complejos tienden a tener mayor varianza.



Relación sesgo - varianza



Sobreajuste - overfitting



Un modelo estaría sobreajustado con unos parámetros estimados $\hat{w}'$ si existe otro conjunto de parámetros $\hat{w}$ tales que:

- 1 – Error entrenamiento ($\hat{w}$) < Error entrenamiento ($\hat{w}'$)
- 2 – Error de generalización ($\hat{w}$) > Error de generalización ($\hat{w}'$)

Conclusión: hay que dividir los datos en dos conjuntos, uno de entrenamiento para ajustar el modelo y otro de prueba para evaluar su desempeño.

Error versus cantidad de datos

