


Modelos de regresión regularizados

Jhon Quiza

Relación sesgo – varianza - complejidad



¿Cómo reducir la complejidad del modelo?

- Penalizar el tamaño de los coeficientes.
- Función de costo = Medida del ajuste + medida de la magnitud de los coeficientes.
- ¿Cómo medir la magnitud de los coeficientes?

Regresión Ridge

Uso de norma L_2

$$L(y, f(\hat{w})) = \text{MSE}(\hat{w}) + \lambda \|\hat{w}\|_2^2$$

$$0 \leq \lambda \leq \infty$$

En forma matricial:

$$L(y, f(\hat{w})) = (y - Hw)^T (y - Hw) + \lambda w^T w$$

Regresión Ridge

Gradiente:

$$\frac{\nabla L}{\nabla \mathbf{w}} = -2\mathbf{H}^T(\mathbf{y} - \mathbf{H}\mathbf{w}) + 2\lambda\mathbf{w}$$


Solución en forma cerrada:

$$\hat{\mathbf{w}}^{\text{ridge}} = (\mathbf{H}^T + \lambda\mathbf{I})^{-1}\mathbf{H}^T\mathbf{y}$$



También tiene solución por gradiente descendiente.

¿Cómo encuentro el λ adecuado?



Si tengo muchos datos...




Si tengo menos datos...



Si tengo menos datos...




Validación cruzada (K-fold cross – validation)



For $k=1, \dots, K$

1. Estimate $\hat{w}_\lambda^{(k)}$ on the training blocks
2. Compute error on validation block: $error_k(\lambda)$


Validación cruzada



For $k=1, \dots, K$

1. Estimate $\hat{\mathbf{w}}_{\lambda}^{(k)}$ on the training blocks
2. Compute error on validation block: $\text{error}_k(\lambda)$

Validación cruzada



For $k=1, \dots, K$

1. Estimate $\hat{\mathbf{w}}_{\lambda}^{(k)}$ on the training blocks
2. Compute error on validation block: $\text{error}_k(\lambda)$

Compute average error: $\text{CV}(\lambda) = \frac{1}{K} \sum_{k=1}^K \text{error}_k(\lambda)$


Validación cruzada



Repeat procedure for each choice of λ

Choose λ^* to minimize $CV(\lambda)$

Flujo completo de selección y evaluación de modelo



Vamos al código...

Regularización Lasso


Costo total = Medida del ajuste + λ (Medida de la magnitud de los coeficientes).

$$L(y, f(\hat{w})) = MSE(\hat{w}) + \lambda \|\hat{w}\|_1$$

$$0 \leq \lambda \leq \infty$$


Algoritmo de optimización – Descenso de coordenadas

- ¡La función de costo lasso no es derivable! No hay solución cerrada, y el algoritmo de gradiente descendiente no se puede usar.
- Algoritmo coordinate descent: minimización coordenada a coordenada.




Regularización lasso versus ridge

Lasso



Ridge



Vamos al código...