


# Modelos de regresión lineal

Jhon Quiza






# Regresión simple




$$y_i = f(x_i) + \epsilon_i$$

$$\mathbb{E}[\epsilon_i] = 0$$



# ¿Qué modelo de $f(x)$ seleccionar?




# Diagrama de bloques del modelo de regresión



# Modelo de regresión lineal simple




# Función de costo



$$RSS(w_0, w_1) = \sum_{i=1}^N (y_i - [w_0 + w_1 x_i])^2$$

# ¿Cuál es la mejor línea?



Otra función de costo muy utilizada es el Error Cuadrático Medio (MSE):

$$MSE(w_0, w_1) = \frac{1}{N} \sum_{i=1}^N (y_i - [w_0 + w_1 x_i])^2$$

# Minimización por mínimos cuadrados

- La mejor línea es la que produzca el menor error (RSS o MSE).
- Este es un problema de optimización.

$$w_0^*, w_1^* = \min_{w_0, w_1} \text{RSS}(w_0, w_1) = \min_{w_0, w_1} \sum_{i=1}^N (y_i - [w_0 + w_1 x_i])^2$$

- Existen 2 maneras de solucionar ese problema:
  - Forma cerrada
  - Forma iterativa

# Algoritmos de optimización de RSS y MSE

- Existen 2 maneras de solucionar ese problema:
  - Forma cerrada
  - Forma iterativa
- Forma cerrada: derivando RSS con respecto a  $W_0$  y  $W_1$  e igualando a 0 se encuentra el valor mínimo:


$$w_1^* = \frac{\sum_{i=1}^N x_i y_i - \frac{1}{N} \sum_{i=1}^N y_i \sum_{i=1}^N x_1}{\sum_{i=1}^N x_i^2 - \frac{1}{N} \sum_{i=1}^N x_i \sum_{i=1}^N x_1}$$

$$w_0^* = \frac{1}{N} \sum_{i=1}^N y_i - \frac{w_1^*}{N} \sum_{i=1}^N x_i$$

# Ejercicio

- Dado el conjunto de datos siguiente, encuentre los pesos óptimos de la función de regresión lineal.


| N | X | Y  |
|---|---|----|
| 1 | 0 | 1  |
| 2 | 1 | 3  |
| 3 | 2 | 7  |
| 4 | 3 | 13 |
| 5 | 4 | 21 |



# Respuesta

- Dado el conjunto de datos siguiente, encuentre los pesos óptimos de la función de regresión lineal.

| N     | X  | Y  | XX | XY  |
|-------|----|----|----|-----|
| 1     | 0  | 1  | 0  | 0   |
| 2     | 1  | 3  | 1  | 3   |
| 3     | 2  | 7  | 4  | 14  |
| 4     | 3  | 13 | 9  | 39  |
| 5     | 4  | 21 | 16 | 84  |
| Sumas | 10 | 45 | 30 | 140 |






$$w_1^* = 5, w_0^* = -1$$

Vamos al código...

# Modelos de regresión múltiple

# Ajuste de los datos con curvas



# Regresión polinómica

Modelo:

$$y_i = w_0 + w_1x_i + w_2x_i^2 + \cdots + w_px_i^p + \varepsilon_i$$

Característica 1 = 1 (constante)    Parámetro 1 =  $w_0$


Característica 2 =  $x$     Parámetro 2 =  $w_1$

Característica 3 =  $x^2$     Parámetro 3 =  $w_2$

...

Característica  $p + 1 = x^p$     Parámetro  $p + 1 = w_p$

# Incorporación de múltiples entradas



# Regresión múltiple lineal - hiperplano

Modelo:

$$y_i = w_0 + w_1 \mathbf{x}_i[1] + w_2 \mathbf{x}_i[2] + \cdots + w_d \mathbf{x}_i[d] + \varepsilon_i$$

Término constante

Parámetro 1 =  $w_0$

Característica 1 =  $\mathbf{x}[1]$

Parámetro 2 =  $w_1$

Característica 2 =  $\mathbf{x}[2]$

Parámetro 3 =  $w_2$


...

Característica d =  $\mathbf{x}[d]$

Parámetro d+1 =  $w_d$

# Notación matricial para una observación


Modelo:

$$y_i = \sum_{j=0}^D w_j h_j(\mathbf{x}_i) + \varepsilon_i$$


The diagram illustrates the matrix notation for a single observation. It shows the equation  $y_i = \sum_{j=0}^D w_j h_j(\mathbf{x}_i) + \varepsilon_i$  being transformed into matrix form. A blue arrow points from the summation to a visual representation. On the left, a pink box labeled  $y_i$  is followed by an equals sign. Then, a 1x7 blue vector is multiplied (indicated by a dot) by a 7x6 green vector. This is followed by a plus sign and a grey box labeled  $\varepsilon_i$ . A blue double-lined equals sign follows. To the right, a 1x6 green vector is multiplied by a 6x7 blue vector, followed by a plus sign and a grey box labeled  $\varepsilon_i$ .

$$y_i = \mathbf{w}^T \mathbf{h}(\mathbf{x}_i) + \varepsilon_i = \mathbf{h}^T(\mathbf{x}_i) \mathbf{w} + \varepsilon_i$$

# Notación matricial para todas las observaciones



$$y = Hw + \epsilon$$

**Dimensiones:**

$y$  es  $N \times 1$

$H$  es  $N \times D$

$w$  es  $D \times 1$

$\epsilon$  es  $N \times 1$

# Notación matricial para la función de costo

- Recordemos que en regresión simple:

$$RSS(w_0, w_1) = \sum_{i=1}^N (y_i - [w_0 + w_1 x_i])^2$$

- Para regresión múltiple:

$$RSS(w_0, w_1, \dots, w_D) = \sum_{i=1}^N (y_i - [w_0 h_0(x_i) + w_1 h_1(x_i) + \dots + w_D h_D(x_i)])^2$$

- En notación matricial:

$$RSS(\mathbf{w}) = \sum_{i=1}^N (y_i - \mathbf{h}(\mathbf{x}_i)^T \mathbf{w})^2 = (\mathbf{y} - \mathbf{H}\mathbf{w})^T (\mathbf{y} - \mathbf{H}\mathbf{w})$$

# Minimización por mínimos cuadrados

- La función de costo en notación matricial queda:



$$\text{RSS}(\mathbf{w}) = \sum_{i=1}^N (y_i - \mathbf{h}(\mathbf{x}_i)^T \mathbf{w})^2 = (\mathbf{y} - \mathbf{H}\mathbf{w})^T (\mathbf{y} - \mathbf{H}\mathbf{w})$$

- La solución en forma cerrada, conocida como OLT (Optimization by Least Squares) es:

$$\hat{\mathbf{w}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$$


# Minimización por mínimos cuadrados

3D plot of RSS with tangent plane at minimum



Tanto RSS como MSE son funciones convexas, así que tienen un mínimo global.

# Forma iterativa – Gradiente descendiente



Si la derivada es positiva, se debe reducir  $w$ , y si la derivada es negativa se debe aumentar  $w$ .


Algoritmo:

Mientras no converja:

$$w^{(t+1)} \leftarrow w^{(t)} - \eta \left. \frac{dg}{dw} \right|_{w^{(t)}}$$

$\eta$  es el tamaño del paso, conocido también como tasa de aprendizaje (learning rate) y es un hiperparámetro del modelo. Si  $\eta$  es muy grande es posible que el algoritmo no converja y si es muy pequeño se puede demorar mucho en converger.

# Forma iterativa – Gradiente descendiente



En múltiples dimensiones:  $\nabla g(w) = \begin{bmatrix} \frac{\partial g}{\partial w_0} \\ \frac{\partial g}{\partial w_1} \\ \vdots \\ \frac{\partial g}{\partial w_p} \end{bmatrix}$

En funciones convexas el algoritmo converge cuando:

$$\nabla g(w) = 0$$

En la práctica, el algoritmo se detiene cuando:

$$|\nabla g(w)| < \epsilon$$

# Notación matricial para gradiente descendente

- Para la  $i$ -ésima característica:

$$w_j^{(t+1)} \leftarrow w_j^{(t)} + 2\eta \left( \sum_{i=1}^N h_j(\mathbf{x}_i)(y_i - \mathbf{h}^T(\mathbf{x}_i)\mathbf{w}^{(t)}) \right)$$

- Para todas las características:

$$\begin{aligned}\mathbf{w}^{(t+1)} &\leftarrow \mathbf{w}^{(t)} - \eta \nabla \text{RSS}(\mathbf{w}^{(t)}) \\ \mathbf{w}^{(t+1)} &\leftarrow \mathbf{w}^{(t)} + 2\eta \mathbf{H}^T(\mathbf{y} - \mathbf{H}\mathbf{w})\end{aligned}$$

# Notación matricial para gradiente y solución cerrada

- Gradiente:

$$\nabla \text{RSS}(\mathbf{w}) = \nabla (\mathbf{y} - \mathbf{H}\mathbf{w})^T (\mathbf{y} - \mathbf{H}\mathbf{w}) = -2\mathbf{H}^T (\mathbf{y} - \mathbf{H}\mathbf{w})$$

- Recordemos que la solución en forma cerrada es:

$$\hat{\mathbf{w}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$$

- Calcular la inversa de una matriz suele ser computacionalmente bastante demandante –  $O(D^3)$  –, y depende de que  $N > D$ . Por lo anterior es que se prefiere el algoritmo de gradiente descendiente.

# Algoritmo completo gradiente descendiente

- Fijar  $\eta$  y  $\epsilon$
- Inicializar  $w_0$  y  $w_1$
- Mientras  $|\nabla g(w)| < \epsilon$ 
  - Calcule los pesos
  - Calcule los errores de predicción
  - Actualice los pesos; por cada peso
    - Calcule la derivada correspondiente
    - Compute el ajuste con el tamaño del paso
    - Compute el nuevo valor del peso
- Compute la magnitud del gradiente
- Chequee convergencia

## Comparación entre los algoritmos

- Para la mayoría de los problemas de ML, no se puede resolver  $\text{gradiente} = 0$ .
- Aún si es posible, el algoritmo de gradiente descendiente puede ser computacionalmente más eficiente.
- Sin embargo, la eficiencia del algoritmo de gradiente descendiente depende de la selección de la tasa de aprendizaje y la tolerancia.



Vamos al código...