

Métricas de evaluación de modelos de clasificación

Jhon Quiza

Objetivos

- Comprender la importancia de las métricas en la evaluación de modelos de clasificación.
- Conocer las métricas más comunes: precisión, recall, F1-score, matriz de confusión, ROC-AUC, entre otras.
- Aprender a interpretar y seleccionar métricas según el problema.
- Aplicar las métricas en un ejemplo práctico.

¿Cómo sabemos que un modelo de clasificación es bueno?

- El objetivo de un clasificador es predecir la clase o categoría de una observación o instancia.
- En ese sentido, un acierto es cuando el modelo predice la clase correcta, y un error cuando predice la clase incorrecta.
- Entonces, en principio un modelo sería mejor que otro sí comete menos errores.
- Pero aunque esto parezca fácil, no lo es tanto, porque depende del contexto.


Empecemos por la matriz de confusión

Es una tabla que resume los resultados de las predicciones de un modelo de clasificación.

Contiene cuatro elementos clave:

- Verdaderos Positivos (VP): Casos en los que el modelo predijo correctamente la clase positiva.
- Falsos Positivos (FP): Casos en los que el modelo predijo incorrectamente la clase positiva (errores Tipo I).
- Verdaderos Negativos (VN): Casos en los que el modelo predijo correctamente la clase negativa.
- Falsos Negativos (FN): Casos en los que el modelo predijo incorrectamente la clase negativa (errores Tipo II).

La matriz de confusión es la base para calcular otras métricas.



Métricas derivadas de la matriz de confusión

- Accuracy (Exactitud): mide la proporción de predicciones correctas sobre el total de predicciones

$$Accuracy = \frac{V_P + V_N}{V_P + V_N + F_P + F_N}$$

- Precision (Precisión): Mide la proporción de predicciones positivas que son correctas.

$$Precision = \frac{V_P}{V_P + F_P}$$

Métricas derivadas de la matriz de confusión

- Recall (Sensibilidad): mide la proporción de positivos reales que fueron identificados correctamente

$$Recall = \frac{V_P}{V_P + F_N}$$

- F1-score: Combina precisión y sensibilidad en una sola métrica.

$$F1 = \frac{Precision * Recall}{Precision + Recall}$$

Precision y recall en contextos médicos

En contextos médicos estas métricas se interpretan así:

- **Precisión:** De todos los casos que el modelo predijo como positivos (presencia de enfermedad), ¿qué porcentaje realmente lo son?
- **Recall (Sensibilidad):** De todos los casos que realmente son positivos (tienen la enfermedad), ¿qué porcentaje fueron correctamente identificados por el modelo?

Precision y recall en contextos médicos

- Una precisión alta indica que el modelo es bueno para identificar correctamente a las personas que realmente tienen la enfermedad. Un modelo así sería útil para **confirmar** diagnósticos.
- Una sensibilidad alta señala que la prueba o modelo es eficaz para detectar la mayoría de los casos de la enfermedad, incluso si esto significa que también identifique a algunas personas sanas como enfermas (falsos positivos). Esto implica que el modelo es bueno para **pruebas de cribado o tamizaje**.

¿Cuándo usar y cuando no usar la exactitud?

Cuando usarla:

- Cuando las clases están balanceadas, es decir, el número de muestras en cada clase es similar.
- Cuando los errores tienen el mismo impacto en todas las clases.
- En problemas donde cada predicción tiene la misma importancia, sin sesgo hacia falsos positivos o negativos.

Ejemplo de uso adecuado:

- Clasificación de imágenes de gatos y perros con un número balanceado de ejemplos.
- Clasificación de correos electrónicos en promociones, social y principal, cuando todas las categorías están bien representadas.

¿Cuándo usar y cuando no usar la exactitud?

Cuando no usarla:

- En datasets desbalanceados, donde una clase es mucho más frecuente que otra. Un modelo trivial que siempre prediga la clase mayoritaria podría obtener una alta exactitud sin ser útil.

Ejemplo donde es engañosa:

- Detección de fraudes bancarios donde el 99% de las transacciones son legítimas. Un modelo que siempre prediga "legítima" tendría 99% de exactitud, pero sería inútil.

¿Cuándo usar y cuando no usar la precisión?

Cuando usarla:

- Cuando el costo de los falsos positivos es alto y queremos minimizar su impacto.
- En situaciones donde una predicción positiva errónea es costosa o riesgosa.

Ejemplo de uso adecuado:

- Filtrado de spam: No queremos marcar como spam correos legítimos (falso positivo).
- Diagnóstico médico para enfermedades raras: Si el tratamiento tiene efectos secundarios peligrosos, es mejor estar seguros antes de diagnosticar la enfermedad.

¿Cuándo usar y cuando no usar la precisión?

Cuando no usarla:

- Cuando los falsos negativos son más problemáticos que los falsos positivos, es decir, cuando queremos asegurarnos de detectar todas las instancias positivas.

Ejemplo donde no es adecuado usarla:

- Detección de cáncer en mamografías: Aquí queremos detectar todos los casos posibles (evitar falsos negativos), aunque haya algunos falsos positivos.

¿Cuándo usar y cuándo no usar la sensibilidad?

Cuando usarla:

- Cuando detectar la mayor cantidad de casos positivos es crucial, sin importar si se incluyen algunos falsos positivos.
- Cuando los falsos negativos tienen un alto costo.

Ejemplo de uso adecuado:

- Diagnóstico de cáncer: Es mejor detectar todos los posibles casos de cáncer, aunque algunas personas sanas sean enviadas a pruebas adicionales.
- Sistemas de alerta de incendios: Prefieres tener algunas falsas alarmas a que se pase un incendio real.

¿Cuándo usar y cuándo no usar la sensibilidad?

Cuando no usarla:

- Cuando los falsos positivos pueden tener consecuencias negativas importantes y deben minimizarse.

Ejemplo de uso inadecuado:

- Filtrado de spam: Si el recall es muy alto, puede clasificar correos importantes como spam.

¿Cuándo usar y cuándo no usar el F1-score?

Cuando usarla:

- Cuando hay desequilibrio de clases y queremos un balance entre precisión y recall.
- Cuando es importante tanto detectar la mayoría de los positivos como evitar muchos falsos positivos.

Ejemplo de uso adecuado:

- Clasificación de sentimientos en redes sociales: No queremos etiquetar erróneamente muchos comentarios, pero tampoco queremos perder mensajes relevantes.
- Detección de fraudes en tarjetas de crédito: Se busca un balance entre atrapar fraudes y no molestar a usuarios legítimos con bloqueos innecesarios.

¿Cuándo usar y cuándo no usar el F1-score?

Cuando no usarla:

- Cuando un error (falso positivo o falso negativo) es mucho más costoso que el otro. En este caso, es mejor optimizar por precisión o recall directamente.

Ejemplo de uso inadecuado:

- Diagnóstico de enfermedades mortales: Si el recall es la prioridad, no deberíamos centrarnos en balancear precisión y recall, sino en maximizar recall.

El reporte de clasificación

- Soporte (support): Número de instancias reales de cada clase en los datos de prueba.
- Macro avg (Promedio macro): Calcula la media aritmética de las métricas individuales de cada clase. Útil cuando queremos tratar todas las clases por igual, sin importar su frecuencia.
- Weighted avg (Promedio ponderado): Calcula el promedio ponderado de precisión, recall y F1-score según el soporte de cada clase. Útil cuando el dataset es desbalanceado y queremos tener en cuenta la distribución real de clases.

	precision	recall	f1-score	support
B	0.97	0.94	0.96	71
M	0.91	0.95	0.93	43
accuracy			0.95	114
macro avg	0.94	0.95	0.94	114
weighted avg	0.95	0.95	0.95	114

Vamos al código...